大模型在电商推荐的应用

张超 /京东健康推荐团队负责人

2024-08-03

目录

大模型推荐技术发展回顾

JDH京东健康

- 视角1：对现有推荐的“改变”程度

16年 开始CTR大模型

存储密集到计算密集

① Behavior sequence – DIN DIEN SIM… life long
② Feature interaction – FM, DCN, Transformers, PPNET …
③ Multimodal, Multi task, Multi obejective… ESMM, PLE…
④ Global hash…

20年 LLM语言大模型

增强Recsys

① Data/Fe - LLM token, prompt engineer for text slot preprocess
② NN Representation - LLM embedding, for directly match; for pre-load + finetune, for u2i or ctr model

24年 技术范式

多级过滤判别到生成式

① LLM as Rec – P5
② Meta GR– all - milestone

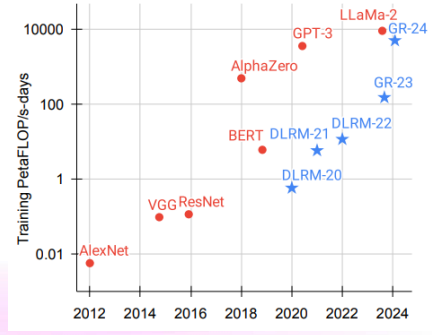

DataFun.

大模型推荐技术发展回顾

JDH京东健康

- 视角2：大模型能力 如何解 推荐曾经发展中的“瓶颈” （1/2）

推荐曾经发展中的“瓶颈”

阶段1：卷数据

- ✓ PC时代数据远不如今天（volume, side info, label），13年移动互联网爆发得到缓解
- ✓ 受限于产品设计（强账号产品少）ID, label和feature均稀疏
- ✓ 13年毕设基于知识地图的学习路径推荐，大量工作在标数据
- ✓ 发论文和打比赛讨论：找数据洗数据 + 树模型打天下（GBDT, 再到后来XGB, 竞赛利器）

阶段2：卷网络表达

- ✓ NN时代到来 – LR换DNN；开始从人工交叉到model交叉
- ✓ 浅层时代CTR代表作 - 百度大规模离散LR，奠定了后来发展的两个走向：高效的计算框架、精细的特征工程；show+click+mlp+ubm，join/update交替训练；
- ✓ NN时代：特工从人交给网络结构，开始了持续至今的模型卷特征交叉表达的时代

阶段3：卷算力&卷Infra

- ✓ transformer，天然可并行的叠罗汉结构让算力有了卷的条件；
- ✓ 行为序列的丰富（长*宽*高）和fea interaction更复杂也给算力和infra提出了新要求
- ✓ 对话场景 VS 推荐场景 用户RT的容忍 对REC算力提出更高的要求

DataFun.

大模型推荐技术发展回顾

JDH京东健康

- 视角2：大模型能力 如何解 推荐曾经发展中的"瓶颈" （2/2）

大模型关键能力：Scaling Law 质变涌现 + World Knowledge 基础理解

	数据瓶颈	NN表达瓶颈	算力&infra 瓶颈
World knowledge	**显性知识：丰富样本行和列** ● 样本生成 Eg. 搜索相关性 – 相似query，通过prompt engine生成hard/easy样本；query suggestion, query rewrite; ● 数据预处理 Eg. 文本类数据kw extract	**隐性知识：作为input or preload更好表达** ● Embedding for user or item understanding Eg. 召回直接用于i2i，or 作为新增的辅助slot放入u2i or ctr模型输入 ● Embedding for model pre-load and finetune Eg. 冷启动，side info给一个相对不错的init	
Scaling law		**Scaling law for 建模表达丰富** ● 召回：deep i2i，头部item精准到全量item精准；u2i, more ps more data get better performance ● 排序：UBM的进化，同质数据空间的长宽高到 异质数据全空间的统一生成式建模；feature interaction layer的不断叠加	**与scaling law同步适配进化的算力和infra** ● 设计适用于并行计算的结构+底层加速计算优化；Eg. 多头注意力等结构叠罗汉，Infer moe sparse 加速推理，各种大模型发展过程带来的加速技巧 ● infra空间换时间，实时换近线，近线转离线；

- Scaling Law条件：工业界海量数据优势+transformer等高并行网络结构+model算力提升+搜推广infra不断拉高quota
- Scaling Law 在NLP的成功 再次坚定 搜推广的尝试方向

JDH京东健康

目录

DataFun.

健康电商推荐系统背景与挑战

京东健康推荐覆盖京东App垂直频道、京东健康APP、健康ABC小程序等多个场域的商品、内容、榜单、店铺、服务等多素材的个性化推荐，承接80+场域的个性化推荐分发。

京东健康APP-综合推荐

京东APP-首页feed流

京东APP-频道推荐

健康中心-综合推荐

互联网医院医生推荐

场景特点：

- ✓ 刚需/知识 VS 兴趣
- ✓ 标品 VS 非标
- ✓ 低频稀疏冷启比高
- ✓ 多场景差异大

目录

大模型结合推荐在JDH落地工作概述

JDH京东健康

生成式推荐召回工作

- 召回：LLM4CB

解决问题：稀疏行为健康新/低频用户的标品召回

解决思路：

第一，利用LLM的世界知识与健康推荐刚需&知识驱动的特点，增强LLM对用户和商品的理解；

第二，利用推荐系统的样本数据，拉齐世界知识和垂域场知识的gap；

第三，LLM推理无法满足召回的RT要求，离线/近线处理，损失覆盖率；

技术挑战：

- ID物料表示：兼容语义和区分度
- 任务对齐：用推荐样本与LLM 精调任务对齐
- Inference：online性能扛不住，精度&覆盖率 trade off

传统推荐在scale up上的工作

- 召回：Deep I2I

wider and deeper. (word2vec, Dssm, BGE based pre-train...)

一路I2I打通全场景（中长尾场景也获得一个相对不错的召回）

- 排序：CTR大模型

CTR model变大，从存储型的大往计算型的大演进

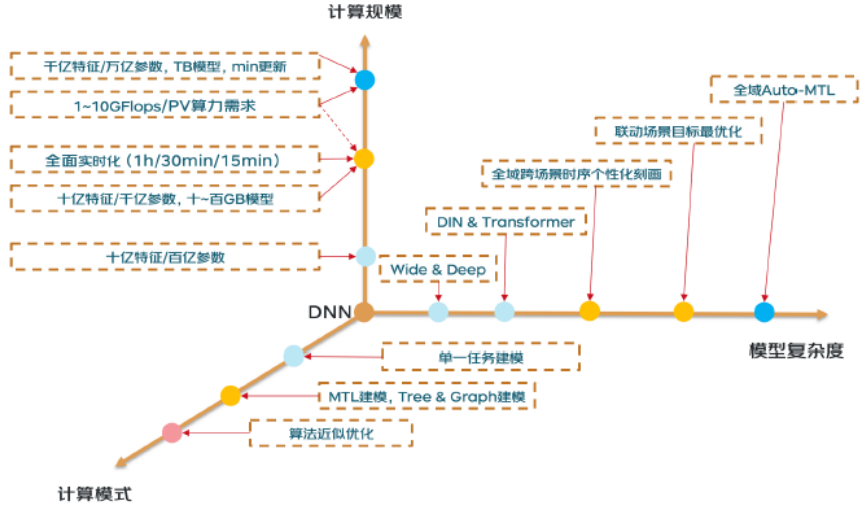

DataFun.

LLM4CB – LLM解稀疏行为用户召回

JDH京东健康

数学建模及系统实现pipeline

$$S_u^p = \{sku \mid EE(p_u, sku) \geq \varepsilon\}$$

$$p_u = \{G(u, cxt) \mid (f(P, G)) \geq \theta\}$$

- ✓ S_u^p表示给定标品p, 召回u感兴趣的sku list
- ✓ EE (p_u, sku) 是用EE的方式筛选得分高的sku
- ✓ p_u表示给定用户u, 生成式的方式产出"可能"的标品集合
- ✓ $f(P, G)$表示生成商品和真实商品的匹配度
- ✓ $G(u, cxt)$ 基于LLM做任务对齐，loss function 最大化序列的似然，负对数似然，实现时等效于一个vocabulary size softmax的交叉熵损失

$$loss = -\sum_{c=1}^{n} y_{ic} log p_{ic}$$

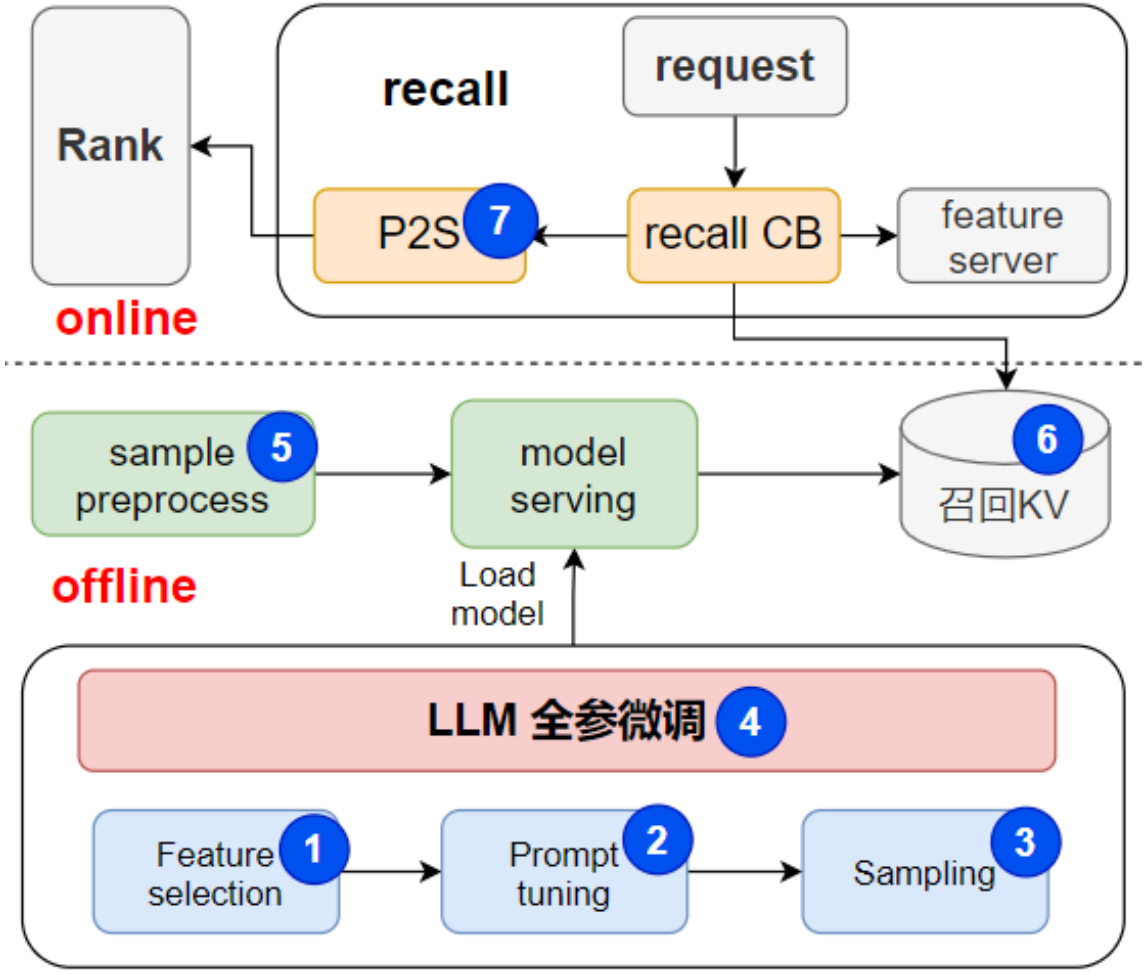

图：LLM4CB pipeline

DataFun.

LLM4CB – LLM解稀疏行为用户召回

JDH京东健康

Prompt Engineering

- ✓ Instruction tuning for feature selection
- ✓ Trade off Efficiency and cover rate for online user
- ✓ Search a better performance of LLM

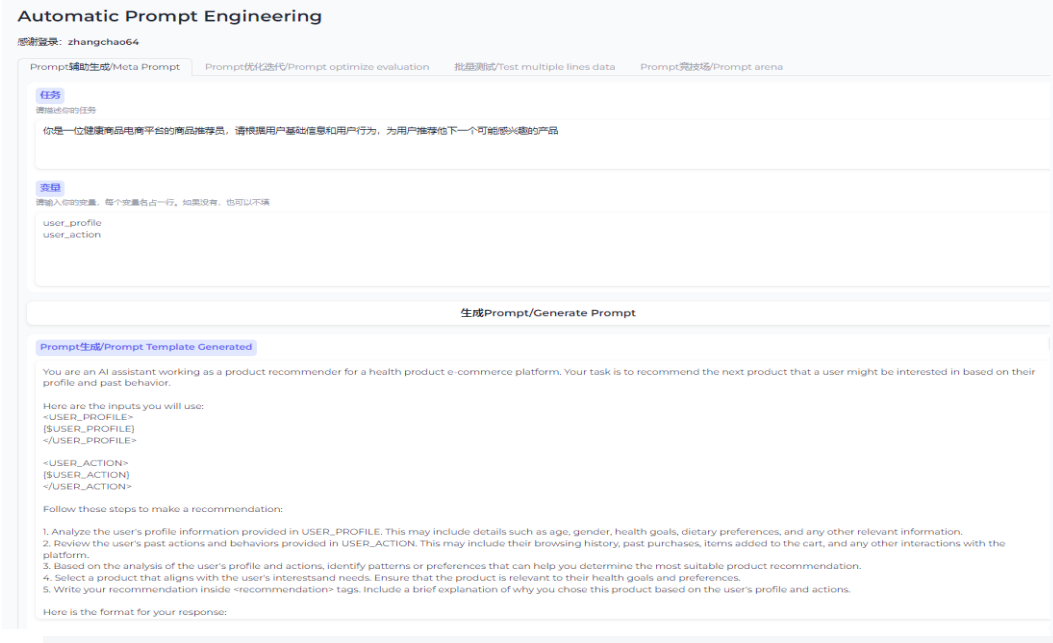


```
{
    "instruction": "你是一位电商平台商品推荐员，请根据用户信息和用户行为，为用户推荐他下一个可能感兴趣的产品", //指令型数据
    "input": "该用户，性别女，年龄36~40岁，婚姻状况未婚，居住城市广东省，职业为未知，学历为专科，未开通平台会员，用户价值中，收入水平中高，购买力中，属于小白领人群，并对箱包皮具品类感兴趣，喜欢在21:00~22:00点浏览商品。",
    "output": "龙胆泻肝片",
    "history": {    }
```

DataFun.

LLM4CB – LLM解稀疏行为用户召回

JDH京东健康

LLM Finetune

- ✓ 保留LLM 全量调参VS加候选池size softmax转多分类任务
- ✓ 小样本+保留世界知识 VS 大样本+更对齐推荐任务

Fine tune 选型原因：

	LLM 全量调参	换softmax frozen LLM
优势	**能力保留度高**：可以充分利用LLM的强大表达能力和大规模参数 **灵活度高**：能够适应不同的推荐任务和数据格式	**简化问题**：将推荐任务转化为多分类问题，简化了模型的输出和目标。 **计算效率高**：只需在LLM基础上增加一层softmax，计算开销较小
劣势	**计算资源消耗大**：全量调参需要大量计算资源和时间，尤其是对于大规模LLM。 **复杂性**：需要处理tokenization和序列化，可能增加实现复杂性。	**信息丢失**：可能无法充分利用LLM的上下文理解能力，特别是对于复杂的推荐场景。 **扩展性差**：如果候选池item数量变化，模型需要重新训练或调整。

本质是在垂域空间和世界知识做选择，当然，更牛逼的是都要，那就是我本身的任务就是同LLM量级的样本和网络，完成一个完美的垂域世界知识

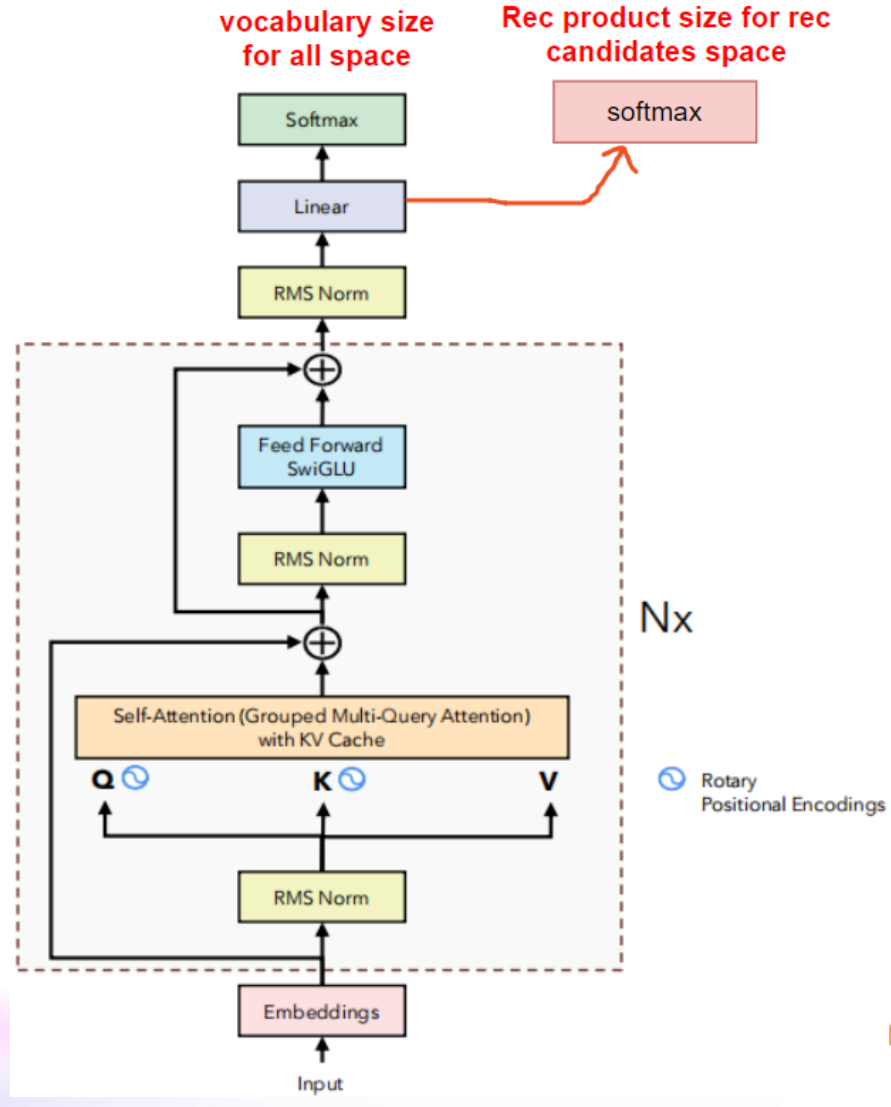

aFun.

LLM4CB – LLM解稀疏行为用户召回

JDH京东健康

Other tips

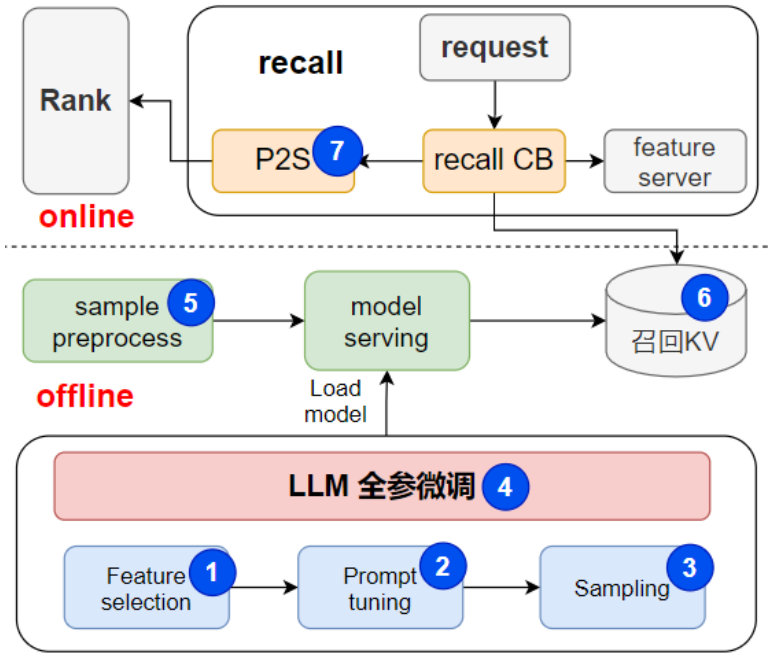

Evaluate

- ✓ AB – 点击下单均有相对百分比个位数增长
- ✓ Hitrate/请求覆盖率 - 离线优化调参

1 Feature selection

- ✓ Low cardinality
- ✓ 贴近自然语言表达的特征
- ✓ 覆盖率高

3 Training sampling

- ✓ 多样性: Multi type of product label
- ✓ 不同类型样本比例 – 实验
- ✓ 样本量 – 实验

5 Inference sampling

- ✓ 覆盖率：拉长样本，N-1对第N天覆盖
- ✓ 性能：infer样本去重

6 Infra methods

- ✓ 时效：实时, 离线, 近线

7 Strategy methods

$$hits_{P_o}^{P_g} = f(P_g, P_o)$$

$$simi_{sku}^{p} = EE(p_u, sku)$$

- ✓ 商品 map 候选池产品名
- ✓ 产品名 到 sku的策略 EE优化

DataFun.

DeepI2I – scale up makes i2i deeper and wider

JDH京东健康

解决什么问题

- ✓ 一路i2i满足各种长尾场景
- ✓ 低频item充分建模
- ✓ Trigger sku 的相似sku 充分拉长

Scaling law 启示解决i2i充分建模

- ✓ 样本 * 参数量 * epoch

deeper

wider

key	Value list			
Sku1	Sku_n	Sku_n+1		
sku2	Sku_m			
…	…	…	…	…
Sku_i	xx	xx	xx	xx

样本	1、原始日志 拓宽source*拉长时长 2、GNN 随机游走，构造低频item样本 3、数据增长，利用LLM
参数	1、IDs and text 均充分表达 2、扩side info 3、pre-trained model 4、dim, layer wider and deeper.

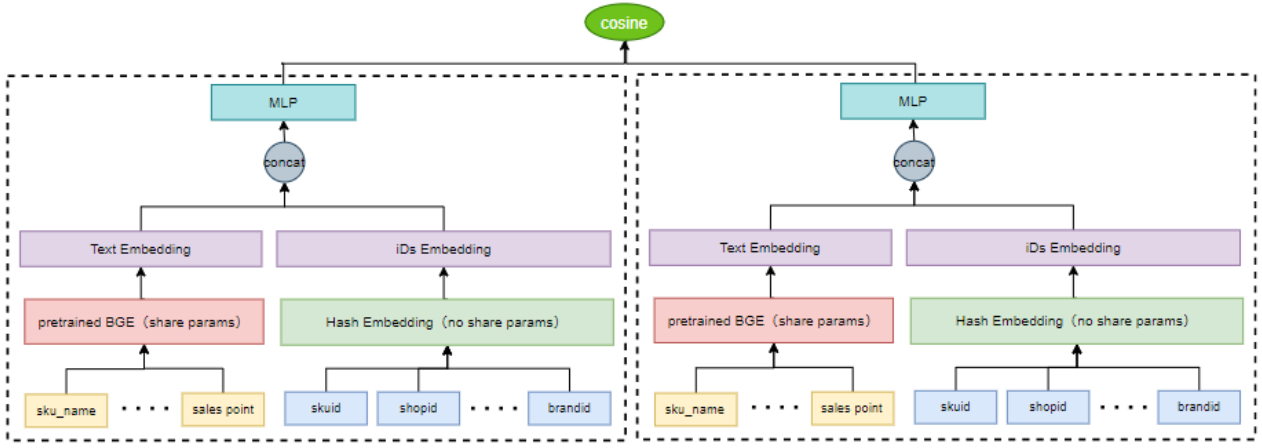

DataFun.

大模型CTR – 传统路子践行scaling law

- 精排：传统路子，ctr model变大
- 长序列、多模态、多目标、多专家、多xx

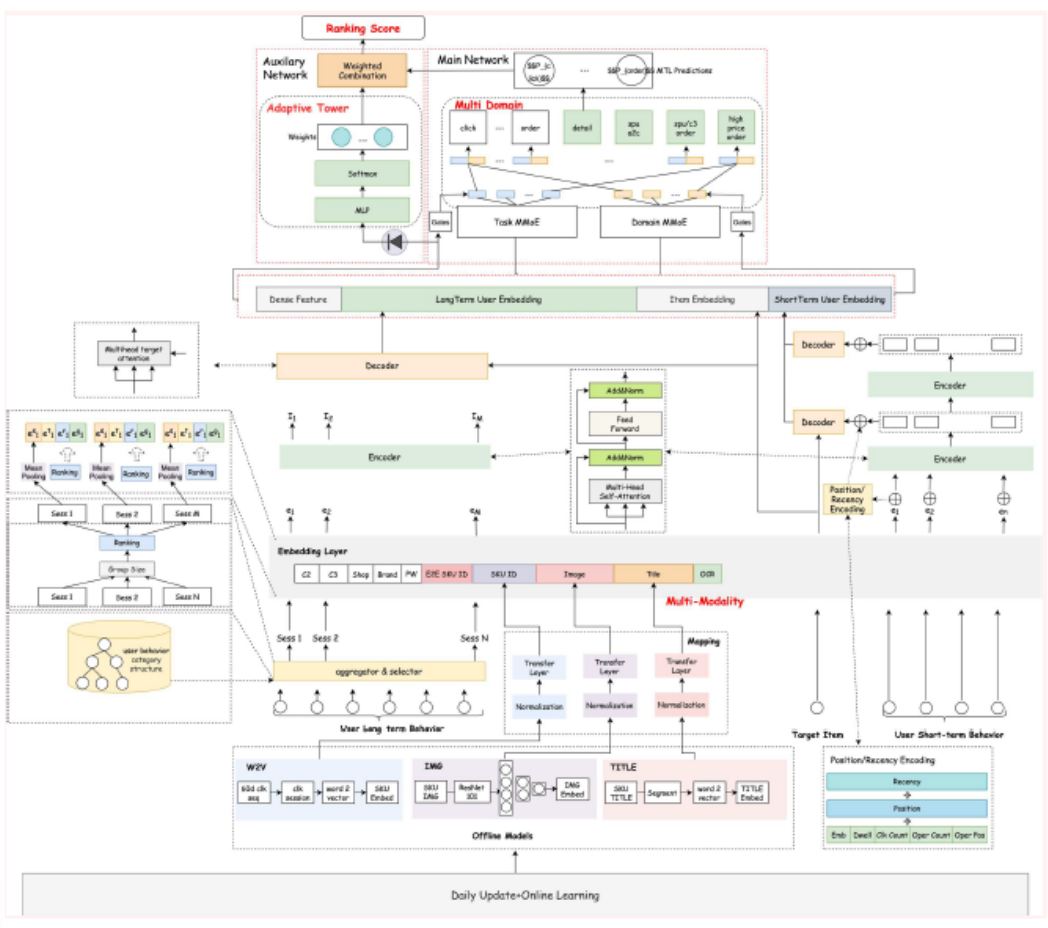

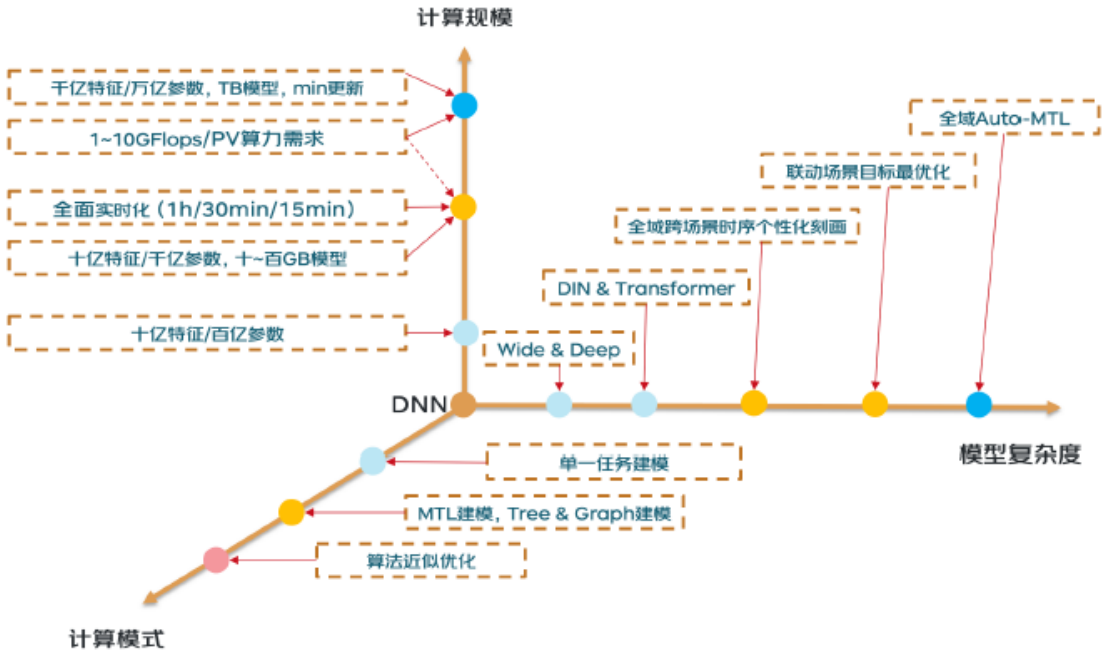

不展开讲，贴2个JD集团兄弟团队的图，不是今天的重点

开放性问题

JDH京东健康

生成式范式 取代 传统多级过滤+判别范式的大范围落地可行性?

- AI上一个技术范式之争：专家系统 VS data driven，树和马的例子 – 计算相似 vs 认知相似
- 电商推荐系统复杂性，非单一技术问题，供给、分发、营销种草和增长为导向的系统性工程
- Scaling law for xx 会成为未来一段时间的主流

JDH京东健康

THANKS

欢迎投递简历，团队现有推荐、搜索、大模型方向的算法HC

联系方式：
zhangchao64@jd.com